

## Contraste de hipótesis y Análisis de Multirresolución de Sistemas Wavelets

Henry Aquino Mosquera

25 de octubre de 2024

- 1 Objetivo y justificación
- 2 Análisis Multiresolución
- 3 Estimación
- 4 Contraste de hipótesis

## 1 Objetivo y justificación

Objetivos

Justificación

## 2 Análisis Multiresolución

## 3 Estimación

## 4 Contraste de hipótesis

## 1 Objetivo y justificación

Objetivos

Justificación

## 2 Análisis Multiresolución

## 3 Estimación

## 4 Contraste de hipótesis

# Objetivos de la investigación

**Objetivo General:** Propuesta de método de contraste de hipótesis para comparar curvas: test con propiedades estadísticas óptimas para un contraste de prueba de hipótesis funcional de la hipótesis nula expresada heurísticamente como sigue:

$$H_0 : \text{“Dos o más grupos de curvas son iguales”}.$$

## Objetivos específicos

- Controlar parámetros del test: controlar los datos atípicos de una serie temporal de datos para un contraste de prueba de hipótesis funcional.
- Elegir el grado de aproximación de una serie temporal de datos para un contraste de prueba de hipótesis funcional.
- implementación del método en el lenguaje R.

## 1 Objetivo y justificación

Objetivos

Justificación

## 2 Análisis Multiresolución

## 3 Estimación

## 4 Contraste de hipótesis

# Justificación

## Justificación:

- Los parámetros utilizados en las ecuaciones incluyen valores promedios, covarianzas entre y dentro de grupos, y otros datos puntuales, como el número de datos o grupos.
- Los parámetros de los test ANOVA/MANOVA no son controlables, ya que dependen completamente de la calidad de la información disponible. Esto puede llevar a evaluaciones inadecuadas, ya que los datos atípicos presentes en la evidencia empírica pueden distorsionar las conclusiones y resultar en resultados sesgados. Por lo tanto, es crucial considerar estos aspectos al realizar el análisis e interpretar los resultados.

## 1 Objetivo y justificación

## 2 Análisis Multiresolución

Sistema intuitivo

Función de escala

## 3 Estimación

## 4 Contraste de hipótesis



- ◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡ ↺ 🔍 ↻

## Idea intuitiva del AMR

El requisito fundamental del Análisis de Multiresolución (AMR) es que los espacios generados por  $V_j$  estén anidados de la siguiente manera:

$$\dots \subset V_{-2} \subset V_{-1} \subset V_0 \subset V_1 \subset V_2 \subset \dots \subset L^2 \quad (1)$$

A partir de (1), podemos comenzar en cualquier  $V_j$ , por ejemplo, en  $j = 0$ , y escribir

$$V_{j_0} \subset V_1 \subset V_2 \subset \dots \subset L^2$$

Visto de otra manera, se puede generar la siguiente expresión

$$V_1 = V_{j_0} \oplus W_0$$

Que se extiende a

$$V_2 = V_{j_0} \oplus W_0 \oplus W_1$$

En general esto da

$$L^2 = V_{j_0} \oplus W_0 \oplus W_1 \oplus \dots \quad (2)$$

# Sistema intuitivo




Figura 1: Función de escala y Espacio de Vectores Wavelet

## ① Objetivo y justificación

## ② Análisis Multiresolución

Sistema intuitivo

Función de escala

## ③ Estimación

## ④ Contraste de hipótesis

# Función de escala

Se genera una familia de parametrización de funciones a partir de la función de escala básica  $\varphi(t) \in L^2(\mathbb{R})$ , cuyo escalado y traslación genera

$$\varphi_{j,k}(t) = 2^{j/2} \varphi(2^j t - k); j, k \in \mathbb{Z}. \quad (3)$$

Para un  $j$  fijo, el espacio generado  $V_j$  sobre  $k$  es

$$V_j = \overline{\text{Span}} \{ \varphi_{jk}(t) : k \in \mathbb{Z} \}$$

## Función de escala

En base a la ecuación (2) se define la función wavelet

$$\psi(t) = \sum_k h_k \varphi(2^j t - k); \quad (4)$$

Puedo generar otro tipo de funciones

$$\psi_{j,k}(t) = 2^{j/2} \psi(2^j t - k); \quad (5)$$

$$W_j = \overline{\text{Span}}\{\psi_{jk}(t) : k \in \mathbb{Z}\}$$

para el caso de combinaciones finitas o infinitas, lo cual nos lleva

$$L^2(\mathbb{R}) = V_{j_0} \oplus W_{j_0} \oplus W_{j_0+1} \dots \quad (6)$$

de ahí que

$$f(t) = \sum_{k=1}^{2^{j_0}-1} c_{j_0,k} \varphi_{j_0,k}(t) + \sum_{j \geq j_0} \sum_{k=0}^{2^j-1} d_{j,k} \psi_{j,k}(t) \quad (7)$$

donde  $f(t) \in L^2(\mathbb{R})$

- 1 Objetivo y justificación
- 2 Análisis Multiresolución
- 3 Estimación**
- 4 Contraste de hipótesis

## Secuencia de funciones

Sea una sucesión de funciones desconocida:

$$f_1, f_2, \dots, f_r; f_i \in L^2(\mathbb{R}), i = 1, 2, \dots, r$$

de donde puedo observar el siguiente proceso.

$$Y_i(t) = \int_0^t f_i(s) ds + \varepsilon W_i(t), i = 1, 2, \dots, r \quad (8)$$

Donde  $\varepsilon$  es  $> 0$

Tomando la derivada la ecuación anterior, se obtiene la siguiente ecuación diferencial (*modelo funcional*)

$$\frac{dY_i(t)}{dt} = \frac{df_i(t)}{dt} + \frac{dW_i(t)}{dt} \quad (9)$$

Donde cada función  $f_i$  será representada de la siguiente forma:

$$f_i(t) = m_0 + \mu(t) + a_i + g_i(t), i = 1, 2, \dots, r \quad (10)$$

donde  $\mu(t)$  es la función media y  $g_i(t)$  la función que distingue a cada función.



## Estructura funcional

Cuando los datos son observables se tiene una secuencia:

$$t_1, t_2, \dots, t_n$$

donde

$$Y_i(t_1), Y_i(t_2), \dots, Y_i(t_n); i = 1, 2, \dots, r$$

Además, el tamaño de la serie para el caso discreto que permita elegir un nivel de resolución será (técnica de espejamiento):

$$J : n = 2^J$$

Por lo tanto, para un  $J$  fijo, el nivel de resolución máximo será finito:

$$Y(t) = \sum_k c_{j_0, k} \varphi_{j_0, k}(t) + \sum_{j \geq j_0}^J \sum d_{j, k} \psi_{j, k}(t) \quad (11)$$

# Aproximación de la series

Propuesta de estimador  $f(t)$

$$\hat{f}(t) = \sum_k c_{j_0,k} \varphi_{j_0,k}(t) + \sum_{j \geq j_0}^{j_1} \sum \hat{d}_{j,k} \psi_{j,k}(t) \quad (12)$$

donde

$$0 < j_0 < j_1 < J \quad (13)$$

# Tener en cuenta

## Metodología de estimación **dada**

- Criterio de elección de  $j_0, j_1$
- Estimación de  $\widehat{d}_{j,k}$

Por lo tanto,

- Mientras que en el universo funcional uno busca estimar los  $y_i(t_n)$ , ( $i \neq n$ ) de cada función,
- en el universo de wavelets, se busca estimar coeficientes  $d_i(j, k)$ , siendo que  $d_{j,k} = \langle f(t), \psi_{j,k}(t) \rangle = \int_{\mathbb{R}} f(t) \psi_{j,k}(t) dt$ .

- 1 Objetivo y justificación
- 2 Análisis Multiresolución
- 3 Estimación
- 4 Contraste de hipótesis**

## Tener en cuenta

## Modelo básico

$$dY_i(t) = f_i(t)dt + dW_i(t)$$

Estimación de  $f(t)$ 

$$\hat{f}(t) = \sum_k c_{j_0,k} \varphi_{j_0,k}(t) + \sum_{j \geq j_0}^{j_1} \sum \hat{d}_{j,k} \psi_{j,k}(t)$$

Los coeficientes son:

$$d_{j,k} = \langle f(t), \psi_{j,k}(t) \rangle = \int_{\mathbb{R}} f(t) \psi_{j,k}(t) dt.$$

donde  $d_{j,k}$  es un parámetro - **transformada de wavelet discreta de  $f(t)$** .

# Transformada aleatoria

A partir del proceso aleatorio  $Y(t)$  tenemos que

$$D_{j,k} = \langle Y(t), \psi_{j,k}(t) \rangle = \int \psi_{j,k}(t) dY(t) = \int \psi_{j,k}(t) f(t) dt + \varepsilon \int \psi_{j,k}(t) dW(t)$$

Donde  $\int \psi_{j,k}(t) dW(t)$  es la integral estocástica de ITO.

$$D_{j,k} = d_{j,k} + \varepsilon \int \psi_{j,k}(t) dW(t); \int \psi_{j,k}(t) dW(t) \sim \mathcal{N}(0, 1)$$

# Metodología

- Para  $H_0 : \mu(t) = 0$ , el modelo  $\bar{Y}(t) \longrightarrow$  ruido blanco Gausseano.
- Para  $H_0 : g_i(t) = 0$ , el modelo  $Y_i - Y(t) \longrightarrow$  ruido blanco Gausseano.

# Metodología

Caso  $H_0 : \mu(t)$

$$\bar{Y}(t) = \frac{1}{r} \sum_{i=1}^r Y(t) = m_0 + \mu(t) + \varepsilon \bar{W}(t)$$

$$d\bar{Y}(t) = (m_0 + \mu(t))dt + \varepsilon d\bar{W}(t) \quad (14)$$

Si  $\mu(t) = 0$  (constante):

$$\bar{D}_{j,k} = \int \psi_{j,k}(t) \mu(t) dt + \varepsilon \int \psi_{j,k}(t) d\bar{W}(t)$$

$$\bar{D}_{j,k} = \bar{d}_{j,k} + \varepsilon \bar{\xi}_{j,k};$$

$$\bar{d}_{j,k} = 0, \text{ si } \mu(t) = 0$$



# Metodología

Para  $H_0 : g_i(t)$

$$d(Y_i - \bar{Y}(t)) = (a_i + g_i(t))dt + \varepsilon(W_i - \bar{W})(t)$$

$$\tilde{D}_{j,k} = \int \psi_{j,k}(t) g_i(t) dt + \varepsilon \bar{\xi}_{j,k}$$

$$\tilde{D}_{j,k} = \tilde{d}_{j,k} + \varepsilon \bar{\xi}_{j,k};$$

$$g_i(t) = 0; \forall_i$$

$$\tilde{d}_{j,k} = 0; \forall_{j,k}$$

# Tests

**Test para  $H_0 : \mu(t) = 0$**

$$X_{j_0}, \dots, X_{j_1}$$

$$X_j = (D_1(j, 1), \dots, D_1(j, 2^j - 1), \dots, D_r(j, 1), \dots, D_r(j, 2^j - 1))$$

Por tanto,  $E(X_j) = \mu_j$ :

$$H_0 : \mu_{j_0} = \dots = \mu_{j_1} = 0$$

$$H_1 : \exists_j, \mu_j \neq 0$$

## Test

Para  $H_0 : g_i(t) = 0$ , construimos las matrices

$$\mathbf{X}_{j_0}, \dots, \mathbf{X}_{j_1} \mathbf{X}_{j_0}, \dots, \mathbf{X}_{j_1} \mathbf{x}_{j_0}, \dots, \mathbf{X}_{j_1} \mathbf{x}_{j_0}, \dots, \mathbf{x}_{j_1}$$

$\mathbf{X}_j$  cuya columna

$$\mathbf{X}_{ji} \mathbf{X}_{ji} \mathbf{x}_{ji} \mathbf{x}_{ji} = (D_i(j, k), \dots, D_i(j, 2^j - 1)^T) \text{ para } i = 1, \dots, r$$

Sea

Gracias!